

Risk Engineering: Multivariate Modelle

ZHAW:

Wirtschaftsingenieurwesen — Wirtschaftsmathematik

Wolfgang Breymann

11. März 2014

Gliederung

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle

Hinweis

Dieser Vorlesung liegt das Buch

Quantitative Risk Management — Concepts, Techniques, Tools
von A. J. McNeil, R. Frey und P. Embrechts (McNeil et al.,
2005)

zugrunde. Ausserdem wird Material aus

P. Embrechts, Lectures at the Federal Reserve Bank of Boston,
September 26-30, 2005 (Embrechts, 2005)

verwendet. Sämtliche Fehler gehen jedoch auf das Konto des Autors
dieser Vorlesung.

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle


Multivariate Risikofaktoren: Allgemeines

Angenommen, $\mathbf{X}_1, \dots, \mathbf{X}_n$ seien beobachtete Risikofaktor-Änderungen, entweder tägliche (log.) Renditen im Zusammenhang von Marktrisiken oder um Renditen zu längeren (monatlichen/jährlichen) Zeithorizonten im Falle von Kreditrisiko. Wie sehen geeignete multivariate Modelle aus?

- **Verteilungsbasierte Modelle:** Die unbedingte Risikomodellierung erfordert geeignete multivariate Verteilungen, die unter der Annahme stationärer Beobachtungen kalibriert werden.
- **Dynamische Modelle:** Bei der bedingten Modellierung werden multivariate Zeitreihenmodelle benutzt, die Risikovorhersagen ermöglichen.

Dieses Kapitel behandelt unbedingte Modelle.


Bivariate tägliche Renditen



BMW- und Siemensaktie: 2000 tägliche Renditen von 1985–1993.

(Aus Embrechts, 2005)

Drei extreme Tage



Die extremen Tage: 19.10.1987, 16.10.1989, 19.08.1991

(Aus P. Embrechts, Lectures at the Federal Reserve Bank of Boston, September 26-30, 2005.)

Geschichte



New York, 19. Oktober 1987



Berliner Mauer

16. Oktober 1989



Der Kremel, 19. August 1991

(Aus P. Embrechts, Lectures at the Federal Reserve Bank of Boston, September 26-30, 2005.)

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle

Multivariate Verteilung & Überlebensfunktionen

Ein d -dim. Zufallsvektor $\mathbf{X} = (X_1, \dots, X_d)^T$ von Risikofaktor-Änderungen hat die gemeinsame Verteilung

$$F_{\mathbf{X}}(\mathbf{x}) = F_{\mathbf{X}}(x_1, \dots, x_d) = P(\mathbf{X} \leq \mathbf{x}) = P(X_1 \leq x_1, \dots, X_d \leq x_d).$$

Die Randverteilung F_i des i -ten Risikos lautet

$$F_i(x_i) = P(X_i \leq x_i) = F(\infty, \dots, \infty, x_i, \infty, \dots, \infty).$$

Manchmal arbeitet man mit der sog. Überlebensfunktion

$$\bar{F}_{\mathbf{X}}(\mathbf{x}) = \bar{F}_{\mathbf{X}}(x_1, \dots, x_d) = P(\mathbf{X} > \mathbf{x}) = P(X_1 > x_1, \dots, X_d > x_d)$$

und den entsprechenden Randverteilungen

$$\bar{F}_i(x_i) = P(X_i > x_i) = \bar{F}(-\infty, \dots, -\infty, x_i, -\infty, \dots, -\infty).$$

Wahrscheinlichkeitsdichten und Unabhängigkeit

Wahrscheinlichkeitsdichten. Wenn die Dichte $f(\mathbf{x}) = f(x_1, \dots, x_d)$ existiert, dann gilt folgende Beziehung:

$$F(x_1, \dots, x_d) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_d} f(u_1, \dots, u_d) du_1 \cdots du_d$$

Unabhängigkeit. Die Komponenten von \mathbf{X} werden paarweise unabhängig genannt genau dann, wenn

$$F(\mathbf{x}) = \prod_{i=1}^d F_i(x_i), \quad \forall \mathbf{x} \in \mathbb{R}^d,$$

oder, falls \mathbf{X} eine gemeinsame Dichte der Form besitzt, genau dann, wenn

$$f(\mathbf{x}) = \prod_{i=1}^d f_i(x_i), \quad \forall \mathbf{x} \in \mathbb{R}^d.$$

Momente

Der **Mittelwertvektor** von \mathbf{X} ist gegeben als

$E(\mathbf{X}) := (E(X_1), \dots, E(X_d))^T$ und die **Kovarianzmatrix** als

$$\text{cov}(\mathbf{X}) = E((\mathbf{X} - E(\mathbf{X}))(\mathbf{X} - E(\mathbf{X}))^T)$$

(unter der Annahme, dass beide Momente endlich sind).

Mit der Schreibweise Σ für $\text{cov}(\mathbf{X})$ ist das Matrixelement (i, j) gegeben als $\sigma_{ij} = \text{cov}(X_i, X_j) = E(X_i \cdot X_j) - E(X_i)E(X_j)$.

Die **Korrelationsmatrix** P von \mathbf{X} hat die Matrixelemente

$$P_{ij} = \rho(X_i, X_j) = \frac{\text{cov}(X_i, X_j)}{\sqrt{\text{var}(X_i)\text{var}(X_j)}},$$

d.h., die gewöhnliche, paarweise lineare Korrelation von X_i und X_j .

Mit der Definition $\Delta := \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{dd}})$ gilt $P = \Delta^{-1}\Sigma\Delta^{-1}$.

Momente II

Mittelwertvektoren und Kovarianzmatrizen verhalten sich sehr einfach unter linearen Operationen auf dem Vektor \mathbf{X} .

Für jede Matrix $B \in \mathbb{R}^{k \times d}$ und jeden Vektor $\mathbf{b} \in \mathbb{R}^k$ gilt

$$\begin{aligned} E(B\mathbf{X} + \mathbf{b}) &= BE(\mathbf{X}) + \mathbf{b} \\ \text{cov}(B\mathbf{X} + \mathbf{b}) &= B \text{cov}(\mathbf{X}) B^T. \end{aligned} \tag{1}$$

Kovarianzmatrizen (und folglich auch Korrelationsmatrizen) müssen **positiv semidefinit** sein; mit $\Sigma = \text{cov}(\mathbf{X})$ folgt sofort aus Gl. (1), dass $\text{var}(\mathbf{a}^T \mathbf{X}) = \mathbf{a}^T \Sigma \mathbf{a} \geq 0$ für beliebige $\mathbf{a} \in \mathbb{R}^d$.

Schätzer für Mittelwertvektor, Kovarianz und Korrelation

Es wird angenommen, die Beobachtungen $\mathbf{X}_1, \dots, \mathbf{X}_n$ sind **iid** oder zumindest **seriell unkorreliert** mit Mittelwert-Vektor μ , endlicher Kovarianzmatrix Σ und Korrelationsmatrix P .

Standard “Methods-of-moments” Schätzer von μ und Σ sind durch den **Stichproben-Mittelwertvektor** $\bar{\mathbf{X}}$ und die **Stichproben-Kovarianzmatrix** S gegeben. Sie sind definiert als

$$\bar{\mathbf{X}} := \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i, \quad S := \frac{1}{n} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^\top.$$

$\bar{\mathbf{X}}$ ist erwartungstreu, aber S hat einen Bias.

Für die erwartungstreu Version gilt $S_u = nS/(n-1)$.

Das Element (j, k) der **Stichproben-Korrelationsmatrix** R ergibt sich als $r_{jk} = s_{jk} / \sqrt{s_{jj}s_{kk}}$.

Mit $D = \text{diag}(\sqrt{s_{11}}, \dots, \sqrt{s_{dd}})$ gilt $R = D^{-1}SD^{-1}$.

Eigenschaften der Schätzer?

- Eigenschaften der Schätzer $\bar{\mathbf{X}}$, S und R hängen stark von der **wahren multivariaten Verteilung** der Beobachtungen ab. Sie sind nicht immer notwendigerweise die besten Schätzer von μ , Σ und P . Im Finanz-Risikomanagement werden diese Schätzer routinemässig benutzt, und dieser Punkt wird oft ausser Acht gelassen.
- Wenn die Daten $\mathbf{X}_1, \dots, \mathbf{X}_n$ iid normalverteilt sind, dann sind $\bar{\mathbf{X}}$ und S die **Maximum-Likelihood-Schätzer** (MLS) von Mittelwertvektor μ und Kovarianzmatrix Σ . Ihr Verhalten als Schätzer ist wohl-bekannt, und das statistische Schließen auf die Modellparameter ist relativ unproblematisch.
- Für Risiko-Faktor-Renditen über kurze Zeitintervalle ist die multivariate Normalverteilung jedoch häufig keine gute Beschreibung, und andere Schätzer des wahren Mittelwertvektors μ und der Kovarianzmatrix Σ können bezüglich **Effizienz** und **Robustheit** geeigneter sein.

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung**
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle

Multivariaten Normalverteilung: Dichte





Die multivariate Normalverteilung hat die **gemeinsame Dichte**

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad \mathbf{x} \in \mathbb{R}^d,$$

wobei $\boldsymbol{\mu} \in \mathbb{R}^d$ und $\Sigma \in \mathbb{R}^{d \times d}$ ist eine positiv semi-definite Matrix.

- Wenn \mathbf{X} Dichte f hat, dann ist der **Mittelwertvektor** dieser Verteilung $E(\mathbf{X}) = \boldsymbol{\mu}$ und die **Kovarianzmatrix** $\text{cov}(\mathbf{X}) = \Sigma$.
- Klarerweise sind die Komponenten von \mathbf{X} genau dann paarweise unabhängig, wenn Σ diagonal ist. Beispielsweise ist $\mathbf{X} \sim N_d(\mathbf{0}, I_d)$ dann und nur dann, wenn X_1, \dots, X_d **iid** $N(0, 1)$ sind, d.h., standard-normalverteilt.

Bivariaten Normalverteilung: Illustration



Links: $\rho = 0.9$; rechts: $\rho = -0.7$.

Multivariate Normalverteilung: Eigenschaften

- Randverteilung sind univariat normalverteilt.
- Linearkombinationen $\mathbf{a}^T \mathbf{X} = a_1 X_1 + \dots + a_d X_d$ sind univariat normalverteilt mit Verteilung $\mathbf{a}^T \mathbf{X} \sim N(\mathbf{a}^T \boldsymbol{\mu}, \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a})$.
- Bedingte Verteilungen sind univariat normalverteilt.
- Die Konvolution zweier unabhängiger, normalverteilter Zufallsvektoren $\mathbf{X} \sim N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ und $\mathbf{Y} \sim N_d(\tilde{\boldsymbol{\mu}}, \tilde{\boldsymbol{\Sigma}})$ ist normalverteilt mit $\mathbf{X} + \mathbf{Y} \sim N_d(\boldsymbol{\mu} + \tilde{\boldsymbol{\mu}}, \boldsymbol{\Sigma} + \tilde{\boldsymbol{\Sigma}})$.
- Summe der Quadrate: $(\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_d^2$ (chi-quadrat).

Simulationsalgorithmus:

- 1 Führe Cholesky-Dekomposition $\boldsymbol{\Sigma} = \mathbf{A} \mathbf{A}^T$ durch.
- 2 Erzeuge Vektor $\mathbf{Z} = (Z_1, \dots, Z_d)^T$ mit iid $Z_i \sim N(0, 1)$.
- 3 Berechne $\mathbf{X} = \boldsymbol{\mu} + \mathbf{A} \mathbf{Z}$.

Testen auf multivariate Normalverteilung

- Die univariaten Randverteilungen müssen normal sein, was sich grafisch mit QQplots beurteilen oder formal mit Hilfe von Tests (z.B. Jarque-Bera oder Anderson-Darling) bestellen lässt.
- Normalität der Randverteilungen ist nicht hinreichend für **gemeinsame** Normalität. Es gibt spezielle numerische Tests (siehe Skript). Grafische Beurteilung ist möglich mit Hilfe der Größen

$$\{(\mathbf{X}_i - \bar{\mathbf{X}})^T S^{-1}(\mathbf{X}_i - \bar{\mathbf{X}}) : i = 1, \dots, n\}.$$

Sie müssen (näherungsweise) eine Stichprobe von einer χ^2_d -Verteilung darstellen, was sich ebenfalls mit Hilfe eines QQPlots grafisch beurteilen lässt.

Multivariate Normalverteilung: Unzulänglichkeiten

- Die Ränder der univariaten Normalverteilung sind **nicht stark genug**; sie geben extremen Ereignissen nicht genug Gewicht.
- **Gleichzeitige** extreme Ereignisse in verschiedenen Randverteilungen sind **zu selten**. Die gemeinsamen Ränder der Verteilung geben gemeinsamen Extremwerten nicht genug Gewicht.
- Die Verteilungen haben eine starke Symmetrie, bekannt als elliptische Symmetrie. Beobachtungen fordern häufig **schiefe** Verteilungen.

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen**
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle

Normale Mischverteilungen: Grundlagen

- Seien $\mathbf{Z} \sim N_d(\mathbf{0}, I_d)$ Vektor standard-normalverteilter, iid ZVs, $W \geq 0$ ist eine nicht-negative, skalare ZV **unabhängig** von \mathbf{Z} und $A \in \mathbb{R}^{d \times k}$ und $\boldsymbol{\mu} \in \mathbb{R}^d$ eine konstante Matrix bzw. Vektor.
- Der Zufallsvektor \mathbf{X} folgt einer (multivariaten) Varianz-Mischung von Normalverteilungen, wenn gilt

$$\mathbf{X} = \boldsymbol{\mu} + \sqrt{W}A\mathbf{Z}. \quad (2)$$

- Direkte Rechnung: $E(\mathbf{X}) = \boldsymbol{\mu}$ und $\text{cov}(\mathbf{X}) = E(W)\Sigma$ mit $\Sigma = AA^T$.
- $\boldsymbol{\mu}$ und Σ heißen **Lagevektor** und **Dispersionsmatrix**.
- Es gilt $\mathbf{X}|W = w \sim N_d(\boldsymbol{\mu}, w\Sigma)$ mit $\Sigma = AA^T$.
- W ist Modell von **Schock** als Folge neuer Information, die die Volatilität **sämtlicher** Komponenten beeinflusst.
- Verteilung von \mathbf{X} ist **Mischung** von Normalverteilungen, aber selbst **nicht normalverteilt**.

Normale Mischverteilungen: Beispiele

- Multivariate 2-Punkt Mischung von Normalverteilungen.

$$W = \begin{cases} k_1 & \text{mit Wahrscheinlichkeit } p \\ k_2 & \text{mit Wahrscheinlichkeit } 1 - p \end{cases} \quad k_1 > 0, k_2 > 0, k_1 \neq k_2.$$

Ließe sich zur Modellierung zweier Regime (normal und extrem) benutzen.

- Multivariate t -Verteilung:

W ist invers-gamma verteilt, $W \sim \text{Ig}(\frac{1}{2}\nu, \frac{1}{2}\nu)$. Dies resultiert in einer multivariaten t -Verteilung mit ν Freiheitsgraden.

Gleichwertig damit: $\nu/W \sim \chi_\nu^2$.

- Symmetrische verallgemeinerte hyperbolische Verteilung:

W folgt einer GIG (verallgemeinerten invers-Gaußschen) Verteilung.

Multivariate t -Verteilung

Dichte:

$$f(\mathbf{x}) = k_{\Sigma, \nu, d} \left(1 + \frac{(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}{\nu} \right)^{-(\nu+d)/2}.$$

mit $\boldsymbol{\mu} \in \mathbb{R}^d$, positiv definiter Matrix $\Sigma \in \mathbb{R}^{d \times d}$, Freiheitsgrade ν und Normierungskonstante $k_{\Sigma, \nu, d} = \frac{\Gamma(\frac{1}{2}(\nu+d))}{\Gamma(\frac{1}{2}\nu)(\pi\nu)^{d/2}|\Sigma|^{1/2}}$.





- Wenn \mathbf{X} Dichte f hat, dann gilt

$$E(\mathbf{X}) = \boldsymbol{\mu} \quad \text{und} \quad \text{cov}(\mathbf{X}) = \frac{\nu}{\nu - 2} \Sigma,$$

mit **Mittelwertvektor** $\boldsymbol{\mu}$ und **Dispersionsmatrix** Σ .


- Wenn Σ diagonal, dann sind die Komponenten von \mathbf{X} **unkorreliert**. Sie sind jedoch **nicht unabhängig**!
- Die multivariate t -Verteilung hat „**Heavy Tails**“.

Bivariate Normalverteilung und t -Verteilung



Bivariate Dichte der Normalverteilung (links) und t -Verteilung (rechts). $\rho = -0.7$, $\nu = 3$. Varianzen gleich 1 in beiden Abbildungen.

Gefittete Normal- und t_3 -Verteilung



2000 simulierte Datenpunkte. Modell: Normalverteilung (links) und t_3 -Verteilung (rechts), gefitted mit Maximum-Likelihood-Methode an BMW-Siemens-Daten.

Multivariate Mittelwert-Varianz-Mischungen

Normale Varianzmischungen haben **elliptische Symmetrie**. Man kann **Asymmetrie und Schiefe** einführen, indem man folgende, allgemeinere Mischungen betrachtet:

$$\mathbf{X} = \boldsymbol{\mu} + W\boldsymbol{\gamma} + \sqrt{W}\mathbf{A}\mathbf{Z},$$

wobei $\boldsymbol{\gamma} \in \mathbb{R}^d$ ein Vektor von Asymmetrieparametern ist und sämtliche anderen Größen wie in Gl. (2) definiert sind.

Für $\boldsymbol{\gamma} = \mathbf{0}$ ergibt sich wieder die elliptische Familie von Varianzmischungen.

Wichtiges Beispiel:

Wenn W einer **GIG-Verteilung** folgt, erhalten wir die verallgemeinerte hyperbolische Verteilungsfamilie.

Momente von Mittelwert-Varianz-Mischungen

- Bei gegebenem Wert $W = w$ gilt für die bedingte Verteilung

$$\mathbf{X}|W = w \sim N_d(\boldsymbol{\mu} + w\boldsymbol{\gamma}, w\Sigma).$$

- Daraus folgt:

$$E(\mathbf{X}) = E(E(\mathbf{X}|W)) = \boldsymbol{\mu} + E(W)\boldsymbol{\gamma} \quad (3)$$

$$\begin{aligned} \text{cov}(\mathbf{X}) &= E(\text{cov}(\mathbf{X}|W)) + \text{cov}(E(\mathbf{X}|W)) \\ &= E(W)\Sigma + \text{var}(W)\boldsymbol{\gamma}\boldsymbol{\gamma}^T, \end{aligned} \quad (4)$$

- Bemerkungen:

- ▶ Die Kovarianzmatrix existiert nur, wenn $\text{var}(W) < \infty$.
(Bei (symmetrischen) Varianzmischungen wird lediglich $E(W) < \infty$ gefordert).
- ▶ Aus (3) und (4) folgt, dass
 - ★ $\boldsymbol{\mu}$ in der Regel nicht der Mittelwertvektor und
 - ★ Σ nicht die Kovarianzmatrix von \mathbf{X} ist.

Verallgemeinerte inverse Gaußsche Verteilung

- Dichte der verallgemeinerten invers-Gaußschen Verteilung:

$$f(w) = C \cdot w^{\lambda-1} \exp\left(-\frac{1}{2}(\chi w^{-1} + \psi w)\right)$$

mit Normierungskonstante

$$C = \frac{\chi^{-\lambda} (\sqrt{\chi\psi})^{\lambda}}{2K_{\lambda}(\sqrt{\chi\psi})}.$$

- K_{λ} bezeichnet die modif. Besselfunktion dritter Art mit Index λ
- Die Parameter erfüllen folgende Bedingungen:
 - ▶ $\chi > 0, \psi \geq 0$, falls $\lambda < 0$;
 - ▶ $\chi > 0, \psi > 0$, falls $\lambda = 0$;
 - ▶ $\chi \geq 0, \psi > 0$, falls $\lambda > 0$.
- Spezialfall:

Wenn $\gamma = \mathbf{0}$ und $\psi = 0$, dann ist die Mischverteilung von (27) eine multivariate t -Verteilung.

Simulation normaler Mischverteilungen

Algorithmus zur Erzeugung von Zufallsvariablen, die einer normalen Mittelwert-Varianz-Mischung folgen:

- 1 Erzeuge $\mathbf{Z} \sim N_d(\mathbf{0}, I_d)$.
- 2 Erzeuge positiv mischende Variable W unabhängig von \mathbf{Z} .
- 3 Berechne $\mathbf{X} = \boldsymbol{\mu} + W\boldsymbol{\gamma} + \sqrt{W}\mathbf{A}\mathbf{Z}$.

Beispiel: t - (und schiefe t -) Verteilung:

$$W \sim \text{I}g\left(\frac{1}{2}\nu, \frac{1}{2}\nu\right).$$

Alternativ kann man $V \sim \chi^2_\nu$ erzeugen und $W = \nu/V$ setzen.

Beispiel: Verallgemeinerte hyperbolische Verteilung:

Erzeuge GIG-verteiltes W mit Hilfe des R-Paketes **ghyp**.

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen**
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle

Verallgemeinerte Hyperbolische Verteilungen: Dichte

Mischung von Normalverteilungen:

$$f(\mathbf{x}) = \int w^{-d/2} \exp \left\{ -\frac{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}{2w} - \frac{\boldsymbol{\gamma}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\gamma}}{2/w} \right\} h(w) dw$$

mit Normierungskonstante

$$C = \frac{e^{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\gamma}}}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}}.$$

Dabei ist h (Dichte von W) die Dichte einer GIG-Verteilung.

Verallgemeinerte Hyperbolische Verteilungen:

Dichte II

$$f(\mathbf{x}) = c \frac{K_{\lambda-d/2} \left(\sqrt{(\chi + Q(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}))(\psi + \boldsymbol{\gamma}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\gamma})} \right) \exp((\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\gamma})}{\left(\sqrt{(\chi + Q(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}))(\psi + \boldsymbol{\gamma}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\gamma})} \right)^{\frac{d}{2} - \lambda}}$$

mit

$$Q(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

und Normierungskonstante

$$c = \frac{(\sqrt{\chi\psi})^{-\lambda} \psi^\lambda (\psi + \boldsymbol{\gamma}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\gamma})^{\frac{d}{2} - \lambda}}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}} K_\lambda(\sqrt{\chi\psi})}.$$

Verallgemeinerte Hyperbolische Verteilungen: Eigenschaften

- Notation:

$$\mathbf{X} \sim GH_d(\lambda, \chi, \psi, \boldsymbol{\mu}, \Sigma, \gamma)$$

- Abschluss unter linearen Operationen:

Sei $\mathbf{X} \sim GH_d(\lambda, \chi, \psi, \boldsymbol{\mu}, \Sigma, \gamma)$ und $\mathbf{Y} = B\mathbf{X} + \mathbf{b}$ mit $B \in \mathbb{R}^{k \times d}$ und $\mathbf{b} \in \mathbb{R}^d$. Dann gilt $\mathbf{Y} \sim GH_k(\lambda, \chi, \psi, B\boldsymbol{\mu} + \mathbf{b}, B\Sigma B^T, B\gamma)$

- ▶ GIG-Parameter ändern sich nicht
- ▶ Randverteilungen leicht zu berechnen:
 $X_i \sim GH_1(\lambda, \chi, \psi, \mu_i, \Sigma_{ii}, \gamma_i)$.
- ▶ Version der Portfoliooptimierung (Mittelwert-Varianz-Methode) auf der Grundlage eines GH-Modells möglich.

Verallgemeinerte Hyperbolische Verteilungen: Eigenschaften II

- Unbestimmtheit der Parameter:
 $GH_d(\lambda, \chi/k, k\psi, \mu, k\Sigma, k\gamma)$ und $GH_d(\lambda, \chi, \psi, \mu, \Sigma, \gamma)$ für jedes $k > 0$ identisch.
- Identifizierungsproblem beim Schätzen.
- Lösung:
Beim Anpassen Vorgabe eines Wertes für $|\Sigma|$
- Beeinflusst Werte der Parameter χ und ψ , Produkt $\chi\psi$ bleibt jedoch invariant.
- Produkt $\bar{\alpha}^2 := \chi\psi$ ist daher nützlicher Parameter zur Beschreibung dieser Verteilungen.
(Nicht möglich für $-1 \leq \lambda \leq 0$ und $\psi = 0$.)

Verallgemeinerte Hyperbolische Verteilungen: Spezialfälle

- Wenn $\lambda = \frac{1}{2}(d + 1)$, d -dimensionale hyperbolische Verteilung. Univariaten Randverteilungen dieser Verteilung haben auch $\lambda = \frac{1}{2}(d + 1)$ haben und sind daher keine 1-dim. hyperbolischen Verteilungen.
- Wenn $\lambda = 1$, dann sind die 1-dim. Randverteilungen hyperbolische Verteilungen sind.
Häufig benutzt in der univariaten Analyse von Finanzrenditen.
- Wenn $\lambda = -\frac{1}{2}$, dann NIG (normal inverse gaussian) Verteilung. Im univariaten Fall ebenfalls häufig für die Analyse von Finanzrenditen. Ähnelt der hyperbolischen Verteilung, jedoch mit etwas stärkeren Rändern.
- Wenn $\lambda > 0$ und $\chi = 0$, dann Grenzfall mit den Namen verallgemeinerte Laplace-, Bessel- oder Varianz-Gamma-Verteilung.

Verallgemeinerte Hyperbolische Verteilungen: Spezialfälle II

- Wenn $\lambda = -\frac{1}{2}\nu$, $\chi = \nu$ und $\psi = 0$, dann asymmetrische oder schiefe t -Verteilung. Die Dichte lautet:

$$f(\mathbf{x}) = c \frac{K_{(\nu+d)/2}(\sqrt{(\nu + Q(\mathbf{x}))\gamma^T \Sigma^{-1} \gamma}) \exp((\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} \gamma)}{(\sqrt{(\nu + Q(\mathbf{x}))\gamma^T \Sigma^{-1} \gamma})^{-(\nu+d)/2} (1 + (Q(\mathbf{x})/\nu))^{(\nu+d)/d}}$$

mit $Q(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ und der Normierungskonstanten

$$c = \frac{2^{1-(\nu+d)/2}}{\Gamma(\frac{\nu}{2})(\pi\nu)^{d/2} |\Sigma|^{1/2}}.$$

Im symmetrischen Fall ($\gamma \rightarrow \mathbf{0}$) reduziert sich die Dichte auf die multivariate Standard- t -Dichte.

GH Familie: Empirische Ergebnisse

	Gauss	t-Modell		NIG-Modell		Hyperbolisch	
Aktie	$\log L$	ν	$\log L$	$\sqrt{\chi\psi}$	$\log L$	$\sqrt{\chi\psi}$	$\log L$

Tägliche Renditen: symmetrische Modelle

AXP	4945.7	5.8	5001.8	1.6	5002.4	1.3	5002.1
EK	5112.9	3.8	5396.2	0.8	5382.5	0.6	5366.0
BA	5054.9	3.8	5233.5	0.8	5229.1	0.5	5221.2
C	4746.6	6.3	4809.5	1.9	4806.8	1.7	4805.0
K	5319.6	5.1	5411.0	1.4	5407.3	1.3	5403.3
MSFT	4724.3	5.8	4814.6	1.6	4809.5	1.5	4806.4
HWP	4480.1	4.5	4588.8	1.1	4587.2	0.9	4583.4
INTC	4392.3	5.4	4492.2	1.5	4486.7	1.4	4482.4
JPM	4898.3	5.1	4967.8	1.3	4969.5	0.9	4969.7
DIS	5047.2	4.4	5188.3	1	5183.8	0.8	5177.6

GH Familie: Empirische Ergebnisse II

	Gauss	t -Modell		NIG-Modell		Hyperbolisch	
Aktie	$\log L$	ν	$\log L$	$\sqrt{\chi\psi}$	$\log L$	$\sqrt{\chi\psi}$	$\log L$
<i>Wöchentliche Renditen: symmetrische Modelle</i>							
AXP	719.9	8.8	724.2	3.0	724.3	2.8	724.3
EK	718.7	3.6	765.6	0.7	764.0	0.5	761.3
BA	732.4	4.4	759.2	1.0	758.3	0.8	757.2
C	656.0	5.7	669.6	1.6	669.3	1.3	669.0
K	757.1	6.0	765.7	1.7	766.2	1.3	766.3
MSFT	671.5	6.3	683.9	1.9	683.2	1.8	682.9
HWP	627.1	6.0	637.3	1.8	637.3	1.5	637.1
INTC	595.8	5.2	611.0	1.5	610.6	1.3	610.0
JPM	681.7	5.9	693.0	1.7	692.9	1.5	692.6
DIS	734.1	6.4	742.7	1.9	742.8	1.7	742.7





GH Familie: Empirische Ergebnisse III

	Gauss	t -Modell		NIG-Modell		Hyperbolisch	
Aktie	$\log L$	ν	$\log L$	$\sqrt{\chi\psi}$	$\log L$	$\sqrt{\chi\psi}$	$\log L$
<i>Wöchentliche Renditen: asymmetrische Modelle</i>							
C	NA	6.1	671.4	1.7	671.3	1.3	671.2
INTC	NA	6.3	614.2	1.8	613.9	1.7	613.3

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen**
- 7 Dimensionsreduktion und Faktormodelle

Elliptische Verteilungen: Bildhafte Einführung



Eine Verteilung heisst **elliptisch** wenn die Linien (im 2-dimensionalen), Flächen (im 3-dimensionalen) oder Hyperflächen (in mehr als 3 Dimensionen) auf einer Ellipse bzw. einem Ellipsoid liegen.

Elliptische Verteilungen: Definition

- Ein Zufallsvektor $\mathbf{X} = (X_1, \dots, X_d)^T$ ist sphärische verteilt, wenn seine Verteilung invariant unter Drehungen und Spiegelungen ist; d.h., wenn für jedes $U \in \mathbb{R}^{d \times d}$ (d.h. Drehungen und Spiegelungen, für die $UU^T = U^T U = I_d$) gilt:

$$U\mathbf{X} \stackrel{d}{=} \mathbf{X}$$

- \mathbf{X} heisst elliptisch, wenn es durch affine Transformation aus dem sphärischen Zufallsvektor $\mathbf{Y} = (Y_1, \dots, Y_k)^T$ hervorgeht:

$$\mathbf{X} \stackrel{d}{=} \boldsymbol{\mu} + A\mathbf{Y},$$

$$A \in \mathbb{R}^{d \times k} \text{ und } \boldsymbol{\mu} \in \mathbb{R}^d.$$

- Eine normale Varianz-Mischverteilungen mit $\boldsymbol{\mu} = \mathbf{0}$ und $\Sigma = I$ ist sphärisch; beliebige normale Varianz-Mischverteilungen sind elliptisch.

Literaturhinweise

- [McNeil et al., 1998]

A. J. McNeil, R. Frey, and P. Embrechts, Quantitative Risk Management. Princeton University Press, Princeton, 2005.

- [Embrechts, 2005]

P. Embrechts, Lectures at the Federal Reserve Bank of Boston, September 26-30, 2005,

http://web.abo.fi/fak/mnf/mate/tammerfors08/embrechts_tuesday.pdf

- [Barndorff-Nielsen and Shephard, 1998]

(Verallgemeinerte hyperbolische Verteilungen)

- [Barndorff-Nielsen, 1997] (NIG Verteilung)

- [Eberlein and Keller, 1995]

- [Prause, 1999] (GH Verteilungen - Dissertation)

- [Fang et al., 1990] (Elliptische Verteilungen)

Risk Engineering: Multivariate Modelle

- 1 Motivation: Multivariate Risikofaktoren
- 2 Grundlagen multivariater Modellierung
- 3 Die multivariate Normalverteilung
- 4 Normale Mischverteilungen
- 5 Verallgemeinerte hyperbolische Verteilungen
- 6 Elliptische Verteilungen
- 7 Dimensionsreduktion und Faktormodelle**

Faktormodelle: Idea

- Die typische Situation:
(Zehn-, Hundert-)Tausende von stochastischen Einflussfaktoren.
- Lassen sich nicht alle modellieren und schon gar nicht schätzen.
- Drastische Dimensionsreduktion ist unerlässlich
- **Idee:**
Erkläre die Zufälligkeit der Komponenten eines d -dim. Vektors \mathbf{X} mit Hilfe einer kleineren Menge **gemeinsamer Faktoren** (= Risikotreiber).

→ Faktormodelle

Faktormodelle: Definition

- **Definition:**

Der Zufallsvektor \mathbf{X} folgt einem p -Faktormodell wenn er in folgender Weise zerlegt werden kann:

$$\mathbf{X} = \mathbf{a} + B\mathbf{F} + \boldsymbol{\varepsilon}, \quad (5)$$

- ① $\mathbf{F} = (F_1, \dots, F_p)'$ eine Zufallsvektor mit **gemeinsamen Faktoren** mit $p < d$ und einer (strikt) positiv definiten Kovarianzmatrix ist;
- ② $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_d)'$ ein Zufallsvektor mit **idiosynkratischen Fehlertermen** ist, unkorreliert und mit verschwindendem Mittelwert;
- ③ $B \in \mathbb{R}^{d \times p}$ eine konstante Matrix der **Faktorladungen** und $\mathbf{a} \in \mathbb{R}^d$ ein konstanter Vektor ist; und
- ④ $\text{cov}(\mathbf{F}, \boldsymbol{\varepsilon}) = E((\mathbf{F} - E(\mathbf{F}))\boldsymbol{\varepsilon}') = 0$.

Anmerkungen zur Theorie der Faktormodelle

- Gl. (5) impliziert, dass die Kovarianzmatrix $\Sigma = \text{cov}(\mathbf{X})$ die Beziehung

$$\text{cov}(\mathbf{X}) = B \text{cov}(\mathbf{F}) B' + \text{cov}(\varepsilon)$$

erfüllt.

Man beachte, dass $\text{cov}(\varepsilon)$ diagonal ist.

- Faktoren lassen sich immer diagonalisieren, sodass gilt:

$$\Sigma = BB' + \text{cov}(\varepsilon). \quad (6)$$

- Wenn umgekehrt (6) für die Kovarianzmatrix Σ eines Zufallsvektors \mathbf{X} erfüllt ist, dann folgt \mathbf{X} dem Modell (5) für gewisse \mathbf{a} , \mathbf{F} und ε .
- Wenn \mathbf{X} zusätzlich normalverteilt ist, dann können für \mathbf{F} und ε unabhängige, normalverteilte Vektoren gewählt werden, sodass die Komponenten von ε unabhängig sind.